

Adaptação de um Modelo Visão-Linguagem Pequeno para Legendagem Técnica de Imagens Portuárias em Português

Alan Soares, Daniel Santos, Lucas Lopes

Instituto de Computação – Universidade Federal da Bahia (UFBA)
Salvador – BA – Brasil

alan.soares@ufba.br, daniel.lopes.santoss@gmail.com,
gglucas811@gmail.com

Abstract. *We evaluate whether a 2B-parameter vision-language model (Qwen3-VL-2B) can be adapted, with 68 training images, to write technical port captions in Brazilian Portuguese. Five variants (zero-shot, connector pre-training, full fine-tuning, LoRA, QLoRA) are compared with a large API model (Gemini Flash). LoRA and QLoRA raise CIDEr from 0.12 to 0.53, beat full fine-tuning with $15\times$ fewer trainable parameters and reach 87% (ROUGE-L) and 95% (BERTScore) of the large model. CLIPScore ranks the variants in reverse.*

Resumo. *Avaliamos se um modelo visão-linguagem de 2 bilhões de parâmetros (Qwen3-VL-2B) pode ser adaptado, com 68 imagens de treino, para gerar legendas técnicas portuárias em português. Cinco variantes (zero-shot, pré-treino do conector, fine-tuning completo, LoRA e QLoRA) são comparadas a um modelo grande via API (Gemini Flash). LoRA e QLoRA elevam o CIDEr de 0,12 para 0,53, superam o fine-tuning completo com $15\times$ menos parâmetros treináveis e atingem 87% (ROUGE-L) e 95% (BERTScore) do modelo grande. O CLIPScore inverte a ordem das variantes.*

1. Introdução

Portos inteligentes (*smart ports*) integram sensores, câmeras e sistemas de informação para dar visibilidade às operações [Molavi et al. 2020, Yang et al. 2018]. Boa parte desses dados é visual, e a legendagem automática de imagens (*image captioning*) os transforma em texto para indexação, relatórios, acessibilidade e agentes baseados em LLM. VLMs grandes fazem isso bem, mas exigem APIs pagas, enviam as imagens a terceiros e conhecem pouco o jargão portuário em português (*portêiner*, *transtêiner*, *reach stacker*, *spreader*). Este trabalho, da Unidade de PLN da disciplina, avalia se um VLM pequeno (SLM) aberto, executável numa GPU de 4 GB, pode ser adaptado a esse domínio com poucos dados, tendo o Porto de Salvador (BA) como cenário-alvo.

1.1. Questões de pesquisa

QP1. Quanto a adaptação ao domínio (pré-treino do conector e fine-tuning) melhora as legendas técnicas do SLM em relação ao zero-shot? **QP2.** LoRA e QLoRA igualam o fine-tuning completo, e a que custo? **QP3.** Qual a distância para um VLM grande, e as métricas sem referência concordam com as de referência?

2. Trabalhos relacionados no contexto de Smart Ports

A literatura de portos inteligentes trata a digitalização como eixo de eficiência: Molavi et al. 2020 propõem um índice de maturidade de *smart ports*, Heilig and Voß 2017 classificam os sistemas de informação portuários, Yang et al. 2018 discutem IoT nos portos e gêmeos digitais [Klar et al. 2023] tornam a percepção do ambiente um requisito. No lado visual, os trabalhos tratam de detecção de navios, como o Sea-Ships [Shao et al. 2018], e de legendagem de imagens de sensoriamento remoto, que vê portos de cima [Lu et al. 2018]. A legendagem evoluiu de codificador-decodificador [Vinyals et al. 2015, Xu et al. 2015] para VLMs ajustados por instrução [Liu et al. 2023]. Em português, os trabalhos são de domínio geral: o #PraCegoVer [Santos et al. 2022]; o GRIT treinado no COCO traduzido [Alencar et al. 2024]; a comparação entre legendas nativas e traduzidas do Flickr30K, em que o ViTucano, especializado em português, supera modelos multilíngues maiores nas métricas de referência, enquanto o GPT-4o lidera no CLIPScore [Bromonschenkel et al. 2026]; e a análise bilíngue de atenção que mostra palavras de mesma função morfossintática com focos semelhantes na imagem [Gondim et al. 2025]. Não encontramos trabalhos de legendagem técnica de cenas portuárias ao nível do solo em português, nem comparações de estratégias de adaptação [Hu et al. 2022, Dettmers et al. 2023] de SLMs para esse domínio.

3. Metodologia

O SLM é o Qwen3-VL-2B-Instruct [Qwen Team 2025] (Apache 2.0, multilíngue): codificador de visão ViT ($\sim 0,4$ B parâmetros), conector ($\sim 0,1$ B) e LLM Qwen3 ($\sim 1,7$ B). A tarefa foi definida como **técnica**: uma frase de 12 a 30 palavras com a operação em curso, os equipamentos, embarcações e cargas e suas relações espaciais, sem nomes próprios, textos legíveis, cor, clima, iluminação ou estado de conservação. As referências foram geradas por um LLM rotulador (Claude Opus 5.5) com glossário portuário e três focos por imagem (operação; objetos e relações; visão geral); por produzir o gabarito, o rotulador não entra na comparação.

3.1. Arquitetura/Pipeline proposto

O *pipeline* (Figura 1) é parametrizado por um único arquivo de configuração. As variantes são: **base** (zero-shot); **pretrain** (pré-treino continuado só do conector, codificador e LLM congelados); **finetune** (conector + todo o LLM); **lora** (conector + adaptadores LoRA [Hu et al. 2022] nas projeções de atenção e MLP do LLM); e **qlora** (idem, LLM em 4 bits NF4 [Dettmers et al. 2023]). As três últimas partem do *pretrain*. O **gold** é um VLM grande de outro fornecedor (Gemini Flash [Gemini Team 2023]) com a mesma instrução, sem circularidade com o rotulador.

As métricas de referência são BLEU [Papineni et al. 2002], ROUGE-L [Lin 2004], CIDEr [Vedantam et al. 2015] (texto em minúsculas, sem pontuação, com acentos) e BERTScore [Zhang et al. 2020] com BERTimbau [Souza et al. 2020]. A aderência imagem-texto usa CLIPScore e RefCLIPScore [Hessel et al. 2021], com CLIP ViT-B/32 [Radford et al. 2021] e codificador de texto multilíngue [Reimers and Gurevych 2020]. O custo inclui parâmetros treináveis, VRAM, tempo de treino e de inferência.




Figura 1. Pipeline do experimento, da coleta à avaliação

4. Resultados

4.1. Configuração do ambiente de experimentação

São 99 imagens do Wikimedia Commons com licenças abertas, 7 delas do Porto de Salvador; após excluir uma fora do domínio, ficaram 68 de treino, 15 de validação e 15 de teste (semente 42). O treino rodou no Colab (NVIDIA L4, 22,5 GB, bf16): 3 épocas, lote efetivo 16, taxa de aprendizado 2×10^{-5} (pretrain), 10^{-5} (finetune, AdamW 8 bits) e 10^{-4} (LoRA/QLoRA, $r = 16$, $\alpha = 32$), imagens com lado de 448 px e *checkpoint* de menor perda de validação. A inferência rodou numa GPU local de 4 GB, com as variantes em 4 bits e *beam search* 3.

Tabela 1. Métricas no teste (N = 15; maior é melhor, exceto Palavras)

Variante	BLEU-4	ROUGE-L	CIDEr	BERTScore	CLIPScore	RefCLIP	Palavras
base	0,027	0,232	0,117	0,653	0,811	0,826	25,7
pretrain	0,086	0,304	0,249	0,703	0,723	0,798	20,9
finetune	0,067	0,307	0,290	0,711	0,701	0,775	20,4
lora	0,142	0,359	0,507	0,737	0,665	0,771	20,9
qlora	0,154	0,382	0,532	0,749	0,678	0,781	20,7
gold	0,225	0,440	0,870	0,790	0,706	0,806	21,8

Tabela 2. Custo de treino (Colab L4) e de inferência (GPU local, 4 bits)

Variante	Treináveis (M)	VRAM (GB)	Treino (min)	Perda val.	Inferência (s/img)
base	0	–	–	–	0,71
pretrain	100,7	8,01	1,7	2,153	0,72
finetune	1821,3	9,18	3,4	1,638	0,88
lora	118,1	8,27	3,6	1,359	1,08
qlora	118,1	8,20	2,7	1,394	1,24

4.2. Experimento 1: adaptação ao domínio

Compara *base*, *pretrain* e *finetune* (Tabela 1). Só ajustar o conector dobra o CIDEr (0,117 para 0,249), eleva o BERTScore em 0,05 e aproxima o tamanho das legendas do das referências ($\sim 20,5$ palavras); o fine-tuning completo acrescenta pouco (CIDEr 0,290). O *base* descreve cores, marcas e o céu (“gancho vermelho com número 75”, “caminhão Maersk”), o que a tarefa exclui. **Resposta à QP1:** a adaptação melhora todas as métricas de referência, e a maior parte do ganho vem do conector, isto é, de ajustar como o LLM lê a imagem portuária.

4.3. Experimento 2: eficiência em parâmetros

Compara *finetune*, *lora* e *qlora* (Tabela 2). Os adaptadores treinam 118 M parâmetros (6,5% do fine-tuning completo) e têm menor perda de validação (1,36 e 1,39 contra 1,64) e CIDEr 75–84% maior. Com 68 imagens, ajustar todos os pesos sobreajusta, e o posto baixo regulariza. Surgem termos do glossário (*reach stacker*, *spreader*), mas também erros de grafia (“contêiners”, “portêinê”) penalizados pelas métricas lexicais. A economia de VRAM do QLoRA foi pequena (8,20 contra 8,27 GB): num modelo de 2 B, o pico vem das ativações e do codificador de visão em 16 bits. **Resposta à QP2:** sim, com 15× menos parâmetros e menos de 4 minutos de treino; a quantização não custou qualidade (a diferença entre os dois está no ruído). O custo aparece na inferência: 1,24 s por imagem contra 0,71 s do *base*, por causa dos adaptadores não fundidos.

4.4. Experimento 3: distância para o modelo grande

O *qlora* atinge 87% do ROUGE-L, 95% do BERTScore e 61% do CIDEr do *gold*, que recebeu o mesmo glossário do rotulador e por isso tem vantagem de vocabulário. O CLIPScore inverte a ordem: o *base* tem o maior valor (0,81), acima do *gold* (0,71), pois o CLIP premia atributos salientes proibidos pela especificação (cor, marcas, céu) e conhece pouco o jargão em português, padrão próximo ao observado por Bromonschenkel et al. 2026. **Resposta à QP3:** a distância para o VLM grande é nítida no CIDEr e pequena nas métricas semânticas; as métricas sem referência discordam das de referência e, aqui, medem aderência visual genérica, não aderência à tarefa.

5. Discussões e Ética

As métricas medem a proximidade ao estilo do rotulador, um LLM sem revisão humana, cujos erros são herdados pelo treino e pelo gabarito. O conjunto é pequeno (15 imagens de teste, CIDEr instável), majoritariamente de portos estrangeiros, com uma execução por variante; o Qwen pode ter visto imagens do Commons no pré-treino, o *gold* Flash baixa o teto e a inferência quantizada pode subestimar as variantes. Quanto à ética, todas as imagens têm licença aberta, com autoria registrada imagem a imagem. Trabalhadores aparecem em algumas cenas; a especificação proíbe nomes e textos legíveis, mas o *pipeline* poderia ser reaproveitado para vigilância de trabalhadores, uso que não endossamos. Um SLM local evita enviar imagens operacionais a terceiros, mas legendas automáticas não substituem a inspeção humana em decisões de segurança.

6. Conclusões e Trabalhos Futuros

Um VLM de 2 B parâmetros, adaptado com 68 imagens e menos de 4 minutos de GPU por variante, passou de legendas genéricas para legendas técnicas em português, com LoRA e QLoRA à frente do fine-tuning completo e próximos de um VLM grande nas métricas semânticas; o CLIPScore, sozinho, não serve para avaliar legendas com especificação técnica. Como trabalhos futuros: ampliar o conjunto para 300 imagens ou mais, com mais fotos do Porto de Salvador; revisão humana do teste por especialistas portuários; várias sementes de treino; e uma linha *base* com o glossário no *prompt*, para separar o ganho de treino do ganho de instrução.

Referências

- Alencar, R. S., Castañeda, W. A. C. and Amadeus, M. (2024). Image captioning for Brazilian Portuguese using GRIT model. *arXiv preprint arXiv:2402.05106*.
- Bromonschenkel, G., Koerich, A. L., Paixão, T. M. and de Oliveira, H. T. A. (2026). Brazilian Portuguese image captioning with transformers: A study on cross-native-translated dataset. *Journal of the Brazilian Computer Society*, 32(1):663–676.
- Dettmers, T., Pagnoni, A., Holtzman, A. and Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36.
- Gemini Team, Google (2023). Gemini: A family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*.
- Gondim, J., Claro, D. B. and Souza, M. (2025). A bilingual analysis of multi-head attention mechanism for image captioning based on morphosyntactic information. *Journal of the Brazilian Computer Society*, 31(1):1063–1076.
- Heilig, L. and Voß, S. (2017). Information systems in seaports: a categorization and overview. *Information Technology and Management*, 18(3):179–201.
- Hessel, J., Holtzman, A., Forbes, M., Le Bras, R. and Choi, Y. (2021). CLIPScore: A reference-free evaluation metric for image captioning. In *Proceedings of EMNLP*, pages 7514–7528.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. and Chen, W. (2022). LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*.
- Klar, R., Fredriksson, A. and Angelakis, V. (2023). Digital twins for ports: Derived from smart city and supply chain twinning experience. *IEEE Access*, 11.
- Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out (ACL Workshop)*, pages 74–81.
- Liu, H., Li, C., Wu, Q. and Lee, Y. J. (2023). Visual instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36.
- Lu, X., Wang, B., Zheng, X. and Li, X. (2018). Exploring models and data for remote sensing image caption generation. *IEEE Transactions on Geoscience and Remote Sensing*, 56(4):2183–2195.
- Molavi, A., Lim, G. J. and Race, B. (2020). A framework for building a smart port and smart port index. *International Journal of Sustainable Transportation*, 14(9):686–700.
- Papineni, K., Roukos, S., Ward, T. and Zhu, W.-J. (2002). BLEU: a method for automatic evaluation of machine translation. In *Proceedings of ACL*, pages 311–318.
- Qwen Team (2025). Qwen3-VL-2B-Instruct. Model card. <https://huggingface.co/Qwen/Qwen3-VL-2B-Instruct>.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S. et al. (2021). Learning transferable visual models from natural language supervision. In *Proceedings of ICML*, pages 8748–8763.
- Reimers, N. and Gurevych, I. (2020). Making monolingual sentence embeddings multilingual using knowledge distillation. In *Proceedings of EMNLP*, pages 4512–4525.
- dos Santos, G. O., Colombini, E. L. and Avila, S. (2022). #PraCegoVer: A large dataset

- for image captioning in Portuguese. *Data*, 7(2):13.
- Shao, Z., Wu, W., Wang, Z., Du, W. and Li, C. (2018). SeaShips: A large-scale precisely annotated dataset for ship detection. *IEEE Transactions on Multimedia*, 20(10):2593–2604.
- Souza, F., Nogueira, R. and Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Brazilian Conference on Intelligent Systems (BRACIS)*, pages 403–417. Springer.
- Vedantam, R., Zitnick, C. L. and Parikh, D. (2015). CIDEr: Consensus-based image description evaluation. In *Proceedings of CVPR*, pages 4566–4575.
- Vinyals, O., Toshev, A., Bengio, S. and Erhan, D. (2015). Show and tell: A neural image caption generator. In *Proceedings of CVPR*, pages 3156–3164.
- Xu, K., Ba, J., Kiros, R., Cho, K., Courville, A., Salakhutdinov, R., Zemel, R. and Bengio, Y. (2015). Show, attend and tell: Neural image caption generation with visual attention. In *Proceedings of ICML*, pages 2048–2057.
- Yang, Y., Zhong, M., Yao, H., Yu, F., Fu, X. and Postolache, O. (2018). Internet of things for smart ports: Technologies and challenges. *IEEE Instrumentation & Measurement Magazine*, 21(1):34–43.
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q. and Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations (ICLR)*.